

Algorítmica

Curso 2023-2024

Grupo Viterbi



PRÁCTICA 5- PROGRAMACIÓN DINÁMICA

Integrantes:

Miguel Ángel De la Vega Rodríguez	miguevrod@correo.ugr.es
Alberto De la Vera Sánchez	joaquinrojo724@correo.ugr.es
Joaquín Avilés De la Fuente	adelaveras01@correo.ugr.es
Manuel Gomez Rubio	e.manuelgmez@go.ugr.es
Pablo Linari Perez	e.pablolinari@go.ugr.es

Facultad de Ciencias UGR
Escuela Técnica Ingeniería Informática UGR
Granada
2023-2024

Índice general

1	Autores	3
2	Equipo de trabajo	4
3	Introducción	5
4	Descripción del Algoritmo	6
4.1	Modelo Oculto de Markov (HMM)	6
4.2	Algoritmo de Viterbi	7
5	Ejemplos de Uso	8
5.1	Lenguaje	8
5.1.1	Desambiguación de palabras	8

Autores

- **Miguel Ángel De la Vega Rodríguez: 20%**
 - Estructura del documento
 - Ejemplos de Uso
- **Joaquín Avilés De la Fuente: 20%**
 - RELLENAR
- **Alberto De la Vera Sánchez: 20%**
 - RELLENAR
- **Manuel Gomez Rubio 20%**
 - RELLENAR
- **Pablo Linari Pérez: 20%**
 - RELLENAR

Apartado 2

Equipo de trabajo

- **Miguel Ángel De la Vega Rodríguez:** (Ordenador donde se ha realizado el compute)
 - AMD Ryzen 7 2700X 8-Core
 - 16 GB RAM DDR4 3200 MHz
 - NVIDIA GeForce GTX 1660 Ti
 - 1 TB SSD NVMe
 - Debian 12 Bookworm
 - Compilador GCC 12.2.0

Introducción

El algoritmo de Viterbi es un algoritmo de programación dinámica utilizado para encontrar la secuencia de estados más probable en un **modelo oculto de Markov (HMM, Hidden Markov Model)**. El algoritmo de Viterbi es ampliamente utilizado en diversos campos, como el lenguaje, la ingeniería de comunicaciones, la robótica, la biología, la medicina, la meteorología, etc.

En este documento, presentamos una descripción detallada del algoritmo de Viterbi, su implementación y ejemplos de uso en diferentes campos, haciendo sobre todo énfasis en el uso de la programación dinámica.

Descripción del Algoritmo

Como bien hemos comentado en la introducción el algoritmo de Viterbi es un algoritmo de programación dinámica utilizado para encontrar la secuencia de estados más probable en un modelo oculto de Markov (HMM, Hidden Markov Model), por lo que en primer lugar pasaremos a explicar dicho modelo así como los elementos que lo componen y su sintaxis matemática, para poder comprender mejor el algoritmo de Viterbi y sus ejemplos.

4.1 Modelo Oculto de Markov (HMM)

Un modelo oculto de Markov (HMM) es un modelo estadístico que describe la secuencia de estados a través de la cual pasa un proceso estocástico. En un HMM, el proceso estocástico es un proceso de Markov, lo que significa que la probabilidad de que el sistema pase a un estado futuro depende únicamente del estado actual y no de los estados anteriores, de forma que el cálculo del estado más probable se hace mediante la probabilidad de transición entre estados y de la probabilidad de emisión de observaciones.

Un HMM se representa mediante una tupla $(Q, V, \pi, A, B,)$ y explicaremos a continuación sus componentes:

- Un conjunto de estados $Q = \{q_1, q_2, \dots, q_N\}$.
- Un conjunto de estados observables $V = \{v_1, v_2, \dots, v_L\}$.
- Un conjunto de probabilidades de transición entre estados $A = \{a_{ij}\}$, donde $a_{ij} = P(q_t = j | q_{t-1} = i)$, es decir, la probabilidad de pasar de un estado i en el instante de tiempo $t - 1$ a un estado j en el instante de tiempo t .
- Un conjunto de probabilidades de las observaciones $B = \{b_j(v_k)\}$, donde $b_j(v_k) = P(o_t = v_k | q_t = j)$, es decir, la probabilidad de observar v_k en el estado j en el instante de tiempo t .
- Un conjunto de probabilidades de estados iniciales $\pi = \{\pi_i\}$, donde $\pi_i = P(q_1 = i)$, es decir, la probabilidad de que en el instante 1 (al inicio) se tenga el estado i .

En dicho modelo, notaremos a la secuencia de observaciones como el conjunto $O = \{o_1, o_2, \dots, o_L\}$ y al conjunto de estados ocultos con mayor probabilidad como $S = \{s_1, s_2, \dots, s_L\}$, donde L es el número de observaciones, por lo que como se podía deducir se tiene el mismo número de observaciones que estados ocultos en la secuencia con mayor probabilidad, pues estos estados serán consecuencia (en parte) de las observaciones dadas.

4.2 Algoritmo de Viterbi

En esta sección procederemos a explicar el **Algoritmo de Viterbi**, donde daremos una explicación detallada de su funcionamiento y del uso de programación dinámica en el mismo.

El algoritmo de Viterbi se basa en la idea de que la probabilidad de la secuencia de estados más probable hasta el instante de tiempo t se puede calcular a partir de la probabilidad de la secuencia de estados más probable hasta el instante de tiempo $t - 1$.

El algoritmo de Viterbi se puede resumir en los siguientes pasos:

- **Inicialización:** Calcular la probabilidad de la secuencia de estados más probable hasta el instante de tiempo $t = 1$, es decir, obtener el estado inicial más probable
- **Recursión:** Calcular la probabilidad de la secuencia de estados más probable hasta el instante de tiempo t a partir de la probabilidad de la secuencia de estados más probable hasta el instante de tiempo $t - 1$.
- **Terminación:** Calcular la probabilidad de la secuencia de estados más probable hasta el instante de tiempo T .
- **Reconstrucción de la secuencia de estados:** Reconstruir la secuencia de estados más probable a partir de las probabilidades calculadas.

El uso de programación dinámica en este caso es claro, tener una matriz de probabilidades donde se almacenen la probabilidad máxima de cada estado hasta el instante de tiempo t , lo que nos permitirá calcular la probabilidad máxima de cada estado hasta el instante de tiempo $t + 1$ de forma eficiente. Por tanto tendremos una matriz \mathcal{M} de L filas (una para cada estado q_k donde $k \in L$) y $T = L$ columnas (una para cada instante de tiempo $t \in T = L$). Recordemos que teníamos la secuencia de observaciones $O = \{o_1, o_2, \dots, o_L\}$.

La matriz \mathcal{M} se inicializa de la siguiente forma:

- $\mathcal{M}[k][1] = \pi_k \cdot b_k(o_1) \forall k \in N$, es decir, la probabilidad de que el estado k sea el estado inicial multiplicado por la probabilidad de que se observe la primera observación en el estado k . Destacar que N representa la cantidad de estados posibles ocultos en el modelo oculto de Markov.

Una vez inicializada la matriz \mathcal{M} , se procede a calcular las probabilidades de la secuencia de estados más probable hasta el instante de tiempo t a partir de la probabilidad de la secuencia de estados más probable hasta el instante de tiempo $t - 1$. Para ello, se utiliza la siguiente fórmula:

- $\mathcal{M}[j][t] = \max_{i=1}^N \{ \mathcal{M}[i][t-1] \cdot a_{ij} \cdot b_j(o_t) \}$, es decir, la probabilidad de la secuencia de estados más probable hasta el instante de tiempo $t - 1$ multiplicada por la probabilidad de transición de i a j multiplicada por la probabilidad de observar o_t en el estado j .

Ejemplos de Uso

El algoritmo de Viterbi es ampliamente utilizado en diversos campos tales como el lenguaje, la ingeniería de comunicaciones, la robótica, la biología, la medicina, la meteorología, etc. A continuación presentamos algunas de las aplicaciones específicas de este algoritmo en distintos campos.

5.1 Lenguaje

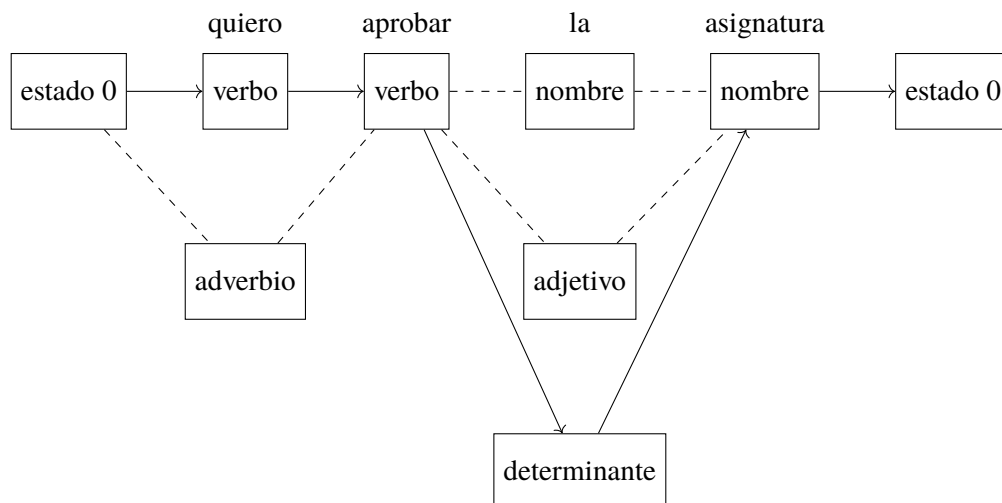
El algoritmo de Viterbi es utilizado en el reconocimiento de voz, en el reconocimiento de escritura a mano, en la corrección de errores en el texto, en la traducción automática, en la generación de texto, en la síntesis de voz, en la transcripción de audio, etc. Veamos un ejemplo de uso de Viterbi en el proceso de desambiguación de palabras en un texto.

5.1.1 Desambiguación de palabras

Cuando queremos procesar el lenguaje natural, es común encontrarnos con palabras que tienen múltiples significados. Por ejemplo, la palabra *privado* está reconocida por la RAE como un adjetivo, un sustantivo y un verbo. Para desambiguar estas palabras cuando procesamos un texto, podemos utilizar el algoritmo de Viterbi, en este caso particular, los elementos del modelo oculto de Markov serían:

- El conjunto Q de estados ocultos (categorías gramaticales)
- El conjunto V de estados observables (palabras)
- El conjunto A de probabilidades de transición entre estados (probabilidades de cambio de categoría gramatical, por ejemplo, que un nombre vaya detras de un verbo)
- El conjunto B de probabilidades de emisión de observaciones (probabilidades de que una palabra pertenezca a una categoría gramatical, por ejemplo, que la palabra *perro* sea un sustantivo es mucho mayor a que sea un adjetivo)

Mostramos un ejemplo para el texto *quiero aprobar la asignatura*:



Donde, los observables son la secuencia de palabras *quiero aprobar la asignatura* y los estados ocultos son las categorías gramaticales de las palabras, que como se puede ver, contemplan sólo un conjunto limitado de categorías gramaticales. Esto se debe a que la probabilidad de pertenencia de determinadas palabras a ciertas categorías gramaticales es 0, lo que simplifica y acelera el proceso de desambiguación.

Aplicación del Algoritmo de Viterbi

El algoritmo de Viterbi se utiliza para encontrar la secuencia más probable de estados ocultos (categorías gramaticales) dada una secuencia de observaciones (palabras). Para nuestro ejemplo, el proceso se desarrolla de la siguiente manera:

- Inicialización:
 - Definir los estados ocultos posibles. Por ejemplo, en nuestro caso, los estados posibles son verbo, nombre, determinante, etc.
 - Definir las probabilidades iniciales para cada estado oculto. Por ejemplo, es muy probable que la primera palabra *quiero* sea un verbo.
 - $\pi(\text{verb}) = P(\text{verb}|\text{estado}_0)$.
- Recursión:
 - Para cada palabra en la secuencia, calcular la probabilidad de que cada posible estado oculto (categoría gramatical) siga a cada estado anterior. Esto se hace utilizando las probabilidades de transición (A) y las probabilidades de emisión (B).
 - Ejemplo: Para la palabra *aprobar*, se calcularía $P(\text{verb}_2|\text{verb}_1) \cdot P(\text{aprobar}|\text{verb}_2)$ para todas las categorías posibles de *aprobar*.
 - Se selecciona el estado que maximiza esta probabilidad.
- Terminación:
 - Una vez procesadas todas las palabras, se selecciona la secuencia de estados que maximiza la probabilidad total de la secuencia observada.
 - Esta secuencia representará las categorías gramaticales más probables para la oración.
- Reconstrucción de la secuencia de estados:

- Utilizando las probabilidades calculadas, se reconstruye la secuencia de categorías gramaticales más probable.
- Por ejemplo: quiero (verbo), aprobar (verbo), la (determinante), asignatura (nombre).